

GenAI Study Assistant - Material testues

Generative AI, ose GenAI, është AI që krijon përmbajtje të re.
Ajo mund të krijojë tekst, përmbledhje, kod, ide, shpjegime dhe përgjigje.

LLM është Large Language Model.
LLM trajnohet me tekst dhe përdoret për të kuptuar e gjeneruar gjuhë natyrore.
Shembuj të përdorimit janë chatbot, përmbledhje, kërkim në dokumente dhe ndihmë në kodim.

Prompt engineering është mënyra si shkruajmë udhëzime të qarta për modelin.
Një prompt i mirë tregon rolin, detyrën, formatin e përgjigjes dhe kufizimet.

Context engineering është zgjedhja e informacionit që i jepet modelit.
Konteksti mund të përfshijë dokumente, shembuj, rregulla sistemi, histori bisede dhe rezultate nga tools.

Embeddings janë përfaqësime numerike të tekstit.
Tekste me kuptim të ngjashëm duhet të kenë embeddings të ngjashme.
Modeli sentence-transformers/all-MiniLM-L6-v2 mund të përdoret për të krijuar embeddings.

Vector search përdoret për të gjetur tekstin me kuptim me të afërt me pyetjen.
FAISS është librari lokale për ruajtje dhe kërkim të vektoreve.

RAG do të thotë Retrieval-Augmented Generation.
Në RAG, sistemi fillimisht ndan dokumentin në chunks.
Pastaj krijon embeddings për çdo chunk dhe i ruan në FAISS.
Kur studenti bën pyetje, sistemi gjen chunks me relevante.
Modeli gjuhësor përdor chunks si kontekst për të kthyer përgjigje.

AI agent është sistem që përdor modelin për të zgjedhur hapa dhe për të përdorur tools.
Një multi-agent system ka disa agjente me role të ndryshme.
Shembull: një agent planifikon, një kërkon informacion, një shkruan përgjigjen dhe një e vlerëson.

MLflow përdoret për të ruajtur eksperimente, parametra, metrika, modele dhe rezultate vlerësimi.
Në GenAI, MLflow mund të ruajë pyetje, prompts, përgjigje dhe kohën e përgjigjes.

Unity Catalog përdoret për governance të të dhënave dhe asetëve AI.
Governance ndihmon në kontrollin e aksesit, pronesinë e të dhënave dhe sigurinë.

Evaluation kontrollon nëse përgjigjet janë të sakta, relevante, të sigurta dhe të bazuara në burime.
RAG evaluation kontrollon cilësinë e retrieval dhe nëse përgjigjja mbështetet në dokumente.

Security në GenAI përfshin mbrojtjen e të dhënave, kufizimin e tools dhe mbrojtjen nga prompt injection.
Prompt injection ndodh kur një input tenton të ndryshojë rregullat e sistemit.

Agent Bricks eshte qasje per ndertimin dhe optimizimin e AI agents per enterprise.
Enterprise AI kerkon governance, evaluation, monitoring, siguri dhe kontroll aksesit.

Ky material perdor vetem mjete falas dhe open-source.
Ky material nuk perdor OpenAI API.